UNIVERSITAS SULTAN AGENG TIRTAYASA

UNTIRTA Jawara
Jujur Adil Wibawa Amanah Religius Akuntabel

Ekstraksi dan Pengolahan Data Web

Web Scraping, Web API, dan Tidy Data



Mata Kuliah: Data Mining

Oleh: Ferdian Bangkit Wijaya, S.Stat., M.Si.

Tujuan dan Peta Materi

Mahasiswa mampu memilih pendekatan akuisisi data web, mengekstraksinya dengan R/Python secara etis, lalu merapikannya menjadi Tidy Data.

1. Landasan, Etika & Legalitas
2. Anatomi HTML/DOM & DevTools
3. Selektor CSS & XPath
4. Ekstraksi Web Statis (R & Python)
5. Situs Dinamis & Otomasi Browser
6. Pengambilan Data via Web API
7. Tidy Data & Data Berantakan
8. Ekspor & Data Pipeline

Daftar Singkatan

Singkatan	Kepanjangan
HTML	HyperText Markup Language
CSS	Cascading Style Sheets
DOM	Document Object Model
XPath	XML Path Language
XML	eXtensible Markup Language
HTTP	HyperText Transfer Protocol
URL	Uniform Resource Locator
API	Application Programming Interface
JSON	JavaScript Object Notation

Singkatan	Kepanjangan
REST	Representational State Transfer
XHR	XMLHttpRequest
CRUD	Create, Read, Update, Delete
CSV	Comma-Separated Values
PII	Personally Identifiable Information
GDPR	General Data Protection Regulation
ToS	Terms of Service
GUI	Graphical User Interface
Regex	Regular Expression

Web Scraping vs Web API

Dua pendekatan utama akuisisi data web. Otomatisasi efisien, tetapi pengambilan tak terkontrol dapat membebani server target, sehingga etika dan kepatuhan hukum menjadi syarat mutlak.

Kriteria	Web API (JSON/HTTP)	Web Scraping (HTML Parsing)
Reliabilitas	Sangat tinggi: struktur JSON konsisten, tidak terpengaruh tampilan/tata letak.	Sedang–rendah: perubahan HTML, kelas CSS, atau desain situs dapat merusak skrip.
Kemudahan integrasi	Sangat mudah: GET/POST langsung menjadi dictionary Python / list R tanpa pembersihan markup.	Perlu parsing lanjutan: DOM, selektor CSS/XPath, karakter escape HTML, transformasi string.
Cakupan (scope)	Terbatas: hanya subset data yang dibuka via endpoint, dengan rate limit ketat.	Sangat luas: seluruh data publik yang tampil di web, ada atau tidak ada API.

Memilih Pendekatan Akuisisi Data

1. API resmi tersedia?

- Jika cakupan data cukup, gunakan Web API: stabil, terstruktur, hemat komputasi.
- Perhatikan rate limit dan API key.

2. Konten ada di HTML awal?

- Gunakan scraping statis: rvest atau requests + BeautifulSoup.
- Uji selektor di DevTools lebih dulu.

3. Dirender JavaScript?

- Cek tab Network: endpoint XHR bisa dipakai langsung.
- Jika tidak, gunakan Selenium (Python) atau chromote (R).

Selalu periksa

- Terms of Service, robots.txt, keberadaan PII, dan beri jeda antar permintaan.

Hukum, Etika, dan Privasi Data

Terms of Service (ToS)

- Kasus HiQ Labs v. LinkedIn (AS): ToS di footer (browse-wrap) tidak otomatis mengikat; click-wrap (buat akun/centang) mengikat.
- Eropa: ToS dapat ditegakkan tanpa persetujuan eksplisit.
- Data publik (tanpa autentikasi) = batas krusial.

Hak Cipta & Fair Use

- Melindungi karya orisinal (sastra, gambar), bukan data faktual (harga, angka, bahan makanan).
- Konten orisinal: Fair Use untuk riset/non-komersial, secukupnya.
- Eropa: hak sui generis melindungi database.

Data Pribadi (PII)

- Nama, email, telepon, tanggal lahir: berat di bawah GDPR.
- OkCupid 2016: data 70.000 pengguna dipublikasikan tanpa anonimisasi, memicu kecaman etis.

Politeness & Anti-blokir

- Beri jeda antar request (hindari HTTP 429/403); R: paket polite (jeda + caching).
- Cek robots.txt, atur User-Agent kustom, jeda acak time.sleep().

Terms of Service (ToS)

Banyak situs mencantumkan batasan ekstraksi otomatis pada halaman Terms and Conditions. Studi kasus: HiQ Labs v. LinkedIn (Amerika Serikat).

Browse-wrap (AS)

- ToS hanya di footer situs.
- Tidak otomatis mengikat pengguna secara hukum.

Click-wrap (AS)

- Pengguna melakukan tindakan eksplisit: membuat akun atau mencentang persetujuan.
- Mengikat secara hukum.

Eropa

- Pengadilan menilai ToS dapat ditegakkan meski tanpa persetujuan eksplisit.

Batas krusial

- Apakah data bersifat publik (dapat diakses tanpa autentikasi) menjadi kriteria kualifikasi hukum.

Hak Cipta dan Fair Use

Yang dilindungi

- Karya orisinal penulisan (original works of authorship): karya sastra, gambar.
- Contoh: undang-undang hak cipta AS.

Yang tidak dilindungi

- Data faktual: daftar bahan makanan, harga, angka statistik.
- Ekstraksi data faktual tidak melanggar hak cipta.

Fair Use

- Konten orisinal dapat dilindungi doktrin Fair Use untuk penelitian atau tujuan non-komersial.
- Dibatasi sesuai kebutuhan.

Eropa: hak sui generis

- Perlindungan khusus atas investasi pembuatan basis data (database rights).

Data Pribadi (PII) dan Kasus OkCupid

Personally Identifiable Information

- Nama, email, nomor telepon, tanggal lahir.
- Implikasi hukum dan etika berat di bawah regulasi seperti GDPR (Eropa).
- Praktik baik (tambahan): minimalkan data, anonimkan/pseudonimkan, simpan aman.

70.000

OkCupid 2016

- Peneliti mengekstrak dan mempublikasikan profil 70.000 pengguna tanpa anonimisasi.
- Data dapat diakses pengguna terdaftar, tetapi publikasi data teridentifikasi tanpa izin memicu kecaman etis dan pelanggaran privasi luas.

Politeness dan Pencegahan Pemblokiran

Jeda antar permintaan

- Hormati kapasitas server; hindari HTTP 429 dan 403.

Paket polite (R)

- Mengatur jeda otomatis.
- Caching agar halaman sama tidak diunduh berulang.

robots.txt dan User-Agent

- Cek robots.txt.
- Jangan pakai User-Agent default pustaka.

Python

```
import time, random
time.sleep(random.uniform(1, 3))  # jeda acak antar permintaan
```

Di R: Sys.sleep(runif(1, min = 1, max = 3)).

Anatomi HTML, DOM, dan DevTools

HTML

```
<html>
<head>
  <title>Judul Halaman</title>
</head>
<body>
  <h1 id='utama'>Judul Utama</h1>
  <p>Teks &amp; <b>teks tebal.</b></p>
  <img src='gambar.png' width='100'>
</body>
</html>
```

Hirarki DOM

- <html> punya anak <head> (metadata) dan <body> (konten); <p> adalah parent dari <b>.
- Tag blok (h1, p, ol, table) membuat baris baru; inline (b, i, a) tidak.
- id unik per dokumen, class boleh berulang; href di <a>, src di <img>.
- Escape: < > & (rvest mengonversi otomatis).

DevTools: F12 / Ctrl+Shift+I (Win/Linux) / Cmd+Option+I (macOS)

- Safari: Settings > Advanced > "Show features for web developers". Panel: Elements, Console, Sources, Network (temukan endpoint API/XHR tersembunyi), Application (cookies, storage), Performance.

Tag Blok, Inline, Atribut, dan Escape

Tag Blok

- <h1>, <section>, <p>, <ol>, <table>
- Membentuk struktur visual utama
- Membuat baris baru

Tag Inline

- <b>, <i>, <a>
- Memformat teks di dalam tag blok
- Tidak membuat baris baru

Atribut Elemen

- id='utama': unik per dokumen
- class='kategori': boleh berulang
- href pada <a>: tautan target
- src pada <img>: lokasi gambar

Karakter Escape HTML

- < dan > menandai tag, maka ditulis: < (<), > (>), & (&). Pustaka rvest mengonversi escape ini secara otomatis.

Developer Tools: Akses dan Panel

Langkah akses Inspect Element

- Chrome & Firefox: klik kanan elemen > Inspect. Shortcut: Cmd+Option+I (macOS), Ctrl+Shift+I (Windows/Linux), atau F12.
- Safari: Safari > Settings > Advanced > centang "Show features for web developers", lalu klik kanan > Inspect Element atau Cmd+Option+I.

Elements / Inspector

- Hirarki HTML & CSS interaktif; periksa tag, id, class.

Console

- Jalankan JavaScript interaktif; pantau log error (debugging).

Sources

- Berkas sumber CSS dan JavaScript yang dimuat situs.

Network

- Pantau lalu lintas HTTP, XHR, fetch API; temukan endpoint API tersembunyi.

Application

- Data sesi, local storage, dan cookies.

Performance

- Kecepatan muat dan performa rendering halaman.

Selektor CSS dan XPath

Jenis	Sintaks	Skenario
Tag HTML	p	Ambil seluruh paragraf dokumen secara masal.
Kelas	.product-item a.title	Ekstrak semua kartu produk e-commerce; pilih tautan judul spesifik.
ID	#first	Elemen unik tanpa duplikat dalam dokumen.
XPath	//table[@id='orders']//tr[2]/td[1]	Sel kolom 1 baris 2 dari tabel ber-ID orders; elemen tanpa kelas unik.

Alat bantu

- SelectorGadget (bookmarklet JavaScript) dan "Copy as Selector" di Chrome DevTools menghasilkan selektor otomatis.

Alat Bantu dan Tips Selektor

SelectorGadget

- Bookmarklet JavaScript yang menghasilkan selektor CSS otomatis.

Copy as Selector

- Fitur Chrome DevTools: klik kanan elemen > Copy > Copy selector.

CSS vs XPath

- CSS: ringkas untuk tag, class, id.
- XPath: jalur hirarki, elemen tanpa kelas unik.

Uji selektor

- Console: document.querySelectorAll(".product-item a.title").
- Selektor terlalu spesifik rapuh terhadap perubahan desain.

Alur Kerja Ekstraksi rvest

1	**Memuat pustaka**	library(tidyverse) dan library(rvest).
2	**Membaca HTML**	read_html(url) mengunduh dan menguraikan berkas HTML dari URL.
3	**Menyeleksi node**	html_elements() untuk semua kecocokan; html_element() untuk 1 output per input (NA jika kosong).
4	**Mengekstrak teks dan atribut**	html_text2() untuk teks murni; html_attr("href") untuk nilai atribut (string).
5	**Parsing tabel**	html_table() mengubah tag <table> menjadi data frame / tibble.

Ekstraksi Statis dengan R (rvest)

```r
library(tidyverse); library(rvest)
html <- read_html("https://rvest.tidyverse.org/articles/starwars.html")
sections <- html |> html_elements("section")

starwars_data <- tibble(
  title = sections |> html_element("h2") |> html_text2(),
  released = sections |> html_element("p") |>
    html_text2() |> str_remove("Released: ") |> parse_date(),
  director = sections |> html_element(".director") |> html_text2(),
  intro = sections |> html_element(".crawl") |> html_text2()
)
# Tabel HTML langsung (IMDB Top 250)
tabel <- html |> html_element("table") |> html_table()
```

Fungsi kunci

- read_html(url): unduh & urai HTML.
- html_elements(): semua kecocokan (0 jika kosong).
- html_element(): selalu 1 output per input, NA jika kosong, menjaga baris saat nesting.
- html_text2() untuk teks; html_attr("href") untuk atribut.
- html_table() ubah <table> menjadi tibble.
- Regex: separate_wider_regex() memisah rank/judul/tahun.

html_elements() vs html_element()

html_elements()

- Menemukan semua elemen yang cocok dengan selektor CSS.
- Jika tidak ada yang cocok, mengembalikan vektor berpanjang 0.

html_element()

- Selalu mengembalikan output sebanyak input.
- Jika tidak ada kecocokan, mengembalikan NA.
- Penting untuk nesting agar baris data tetap terjaga.

Ekstraksi teks dan atribut

- html_text2(): teks murni, konversi teks bersarang lebih baik daripada html_text().
- html_attr("nama_atribut"): nilai atribut (href, src), selalu bertipe string.

Parsing tabel

- html_table(): otomatis mengonversi tag <table> menjadi data frame / tibble.
- Alur: read_html(url) > html_elements() > html_text2() / html_attr().

Kasus IMDB Top 250: Tabel dan Regex

```r
url <-
"https://web.archive.org/web/20220201012049/https://www.imdb.com/chart/top/"
html <- read_html(url)

# 1. Parsing tabel HTML utama
table_data <- html |>
  html_element("table") |>
  html_table()

# 2. Pembersihan teks & pemisahan kolom (regex)
ratings <- table_data |>
  select(rank_title_year = `Rank & Title`,
         rating = `IMDb Rating`) |>
  mutate(rank_title_year =
    str_replace_all(rank_title_year, "\\n +", " ")) |>
  separate_wider_regex(
    rank_title_year,
    patterns = c(
      rank = "\\d+", "\\. ",
      title = ".+", " +\\(",
      year = "\\d+", "\\)"
    )
  )
```

```r
# 3. Atribut 'title' pada <td><strong>
ratings_complete <- ratings |>
  mutate(
    rating_n_raw = html |>
      html_elements("td strong") |>
      html_attr("title")
  ) |>
  separate_wider_regex(
    rating_n_raw,
    patterns = c(
      "[0-9.]+ based on ",
      number = "[0-9,]+",
      " user ratings"
    )
  ) |>
  mutate(number = parse_number(number))
```

UNIVERSITAS SULTAN AGENG TIRTAYASA

Ekstraksi Statis dengan Python

UNTIRTA Jawara
Jujur Adil Wibawa Amanah Religius Akuntabel

Python

```
import requests, csv
from bs4 import BeautifulSoup
url = "https://contoh.com"
headers = {"User-Agent": "DataEngineerBot/1.0 (+https://contoh.com/bot)"}
response = requests.get(url, headers=headers)
if response.status_code == 200:
    soup = BeautifulSoup(response.text, "html.parser")
    a = soup.select("h2.title")              # CSS selector
    b = soup.find_all("h2", class_="title")  # tag + atribut
    with open("hasil_ekstraksi.csv", "w", newline="",
              encoding="utf-8") as f:
        w = csv.writer(f); w.writerow(["judul"])
        for item in b:
            w.writerow([item.get_text(strip=True)])
else:
    print(f"Gagal. Status: {response.status_code}")
```

Alur kerja

- Instal: pip install requests beautifulsoup4.
- GET dengan User-Agent kustom.
- Verifikasi status_code == 200.
- Parsing dengan BeautifulSoup.
- select() = CSS; find_all() = tag + atribut.
- get_text(strip=True) lalu ekspor CSV.

Situs Dinamis dan Otomasi Browser

Client-side rendering: rvest/requests hanya mengunduh HTML awal yang sering kosong. Data dimuat setelah JavaScript berjalan, sehingga dibutuhkan simulasi browser penuh.

Selenium

```
driver = webdriver.Chrome()
driver.get("https://www.scrapethissite.com/pages/forms")
box = driver.find_element(By.ID, "q")
box.send_keys("kings")
driver.find_element(By.XPATH,
    "//input[@type='submit']").click()
wait = WebDriverWait(driver, 10)   # explicit wait
tbl = wait.until(EC.presence_of_element_located(
    (By.CLASS_NAME, "table")))
tbl.screenshot("table_screenshot.png")
options.add_argument("--headless=new")
options.add_argument(f"--proxy-server={PROXY}")
driver.quit()
```

Catatan penting

- Selenium (Python): klik, isi form, navigasi; butuh WebDriver sesuai versi browser.
- Headless: tanpa GUI, cepat, cocok untuk server. Proxy: cegah blokir IP.
- R: paket chromote mengontrol Chrome di latar belakang.
- Paginasi statis (quotes.toscrape.com): ikuti href tombol Next dengan tryCatch + Sys.sleep(runif(1,1,3)); situs AJAX/infinite scroll butuh Selenium/chromote.
- Produksi: rate limiting, exponential backoff, fault tolerance.

Alur Kerja Otomasi Selenium

1	**Instalasi dan konfigurasi**	pip install selenium; unduh ChromeDriver yang versinya sesuai browser.
2	**Inisialisasi dan navigasi**	webdriver.Chrome() lalu driver.get(url).
3	**Interaksi elemen**	find_element (By.ID / By.XPATH), send_keys() mengisi formulir, click() menekan tombol.
4	**Explicit Wait**	WebDriverWait + presence_of_element_located memastikan rendering dinamis selesai.
5	**Screenshot**	element.screenshot(), driver.save_screenshot(), zoom 50% untuk seluruh halaman.
6	**Penutupan sesi**	driver.quit() menutup browser dan mengakhiri proses driver.

Selenium: Instalasi, Navigasi, Interaksi

Python

```
# pip install selenium
# Unduh WebDriver (ChromeDriver) yang
# versinya sesuai browser utama
from selenium import webdriver
from selenium.webdriver.common.by import By
from selenium.webdriver.support.ui import (
    WebDriverWait)
from selenium.webdriver.support import (
    expected_conditions as EC)

driver = webdriver.Chrome()
driver.get(
  "https://www.scrapethissite.com/pages/forms")
```

Python

```
# Elemen formulir pencarian (ID)
search_box = driver.find_element(By.ID, "q")
# Isi formulir dengan teks masukan
search_box.send_keys("kings")
# Tombol cari + click() eksplisit
submit_button = driver.find_element(
    By.XPATH, "//input[@type='submit']")
submit_button.click()
# Explicit Wait: tunggu rendering dinamis
wait = WebDriverWait(driver, 10)
table_element = wait.until(
    EC.presence_of_element_located(
        (By.CLASS_NAME, "table")))
print(table_element.text)
```

Selenium Lanjut dan chromote (R)

Python

```
# Screenshot elemen / jendela / seluruh halaman
table_element.screenshot("table_screenshot.png")
driver.save_screenshot("full_window.png")
driver.execute_script(
    "document.body.style.zoom='50%'")
driver.save_screenshot("page_screenshot.png")
driver.quit()  # tutup browser & driver
```

Python

```
from selenium.webdriver.chrome.options import Options
options = Options()
options.add_argument("--headless=new")  # headless
PROXY = "10.0.0.1:8080"
options.add_argument(f'--proxy-server={PROXY}')
driver = webdriver.Chrome(options=options)
```

Headless Mode

- Browser di latar belakang tanpa GUI.
- Lebih cepat, hemat sumber daya, ideal di server non-GUI.

Integrasi Proxy

- Mencegah pemblokiran IP dengan mengalihkan lalu lintas lewat server proxy.

chromote (R)

- Mengontrol Google Chrome di latar belakang.
- Menjalankan JavaScript, memuat konten dinamis, mengetik teks dan mengeklik tombol.

Alur Loop Paginasi

1	**Fungsi scrape_page()**	Ekstraksi quote dan author dari satu halaman menjadi tibble.
2	**Inisialisasi kontrol**	base_url, next_page_path = "/page/1/", page_count, max_pages = 10, all_quotes kosong.
3	**Eksekusi aman**	tryCatch: jika galat, beri warning dan lanjut (fault tolerance).
4	**Politeness**	Sys.sleep(runif(1, 1, 3)) memberi jeda acak antar permintaan.
5	**Cari tombol Next**	Ambil href dari .pager .next a; berhenti jika NA atau melewati max_pages.
6	**Simpan hasil**	write.csv(all_quotes, "all_quotes.csv", row.names = FALSE).

Paginasi Multi-Halaman (quotes.toscrape.com)

R

```r
library(rvest)
library(tidyverse)
# 1. Fungsi ekstraksi satu halaman
scrape_page <- function(url) {
  html <- read_html(url)
  tibble(
    quote = html |>
      html_elements(".quote .text") |>
      html_text2(),
    author = html |>
      html_elements(".quote .author") |>
      html_text2()
  )
}
# 2. Inisialisasi kontrol paginasi
base_url <- "http://quotes.toscrape.com"
next_page_path <- "/page/1/"
page_count <- 1
max_pages <- 10
all_quotes <- tibble()
```

R

```r
# 3. Loop paginasi + fault tolerance & rate limiting
while (!is.na(next_page_path) && page_count <= max_pages) {
  current_url <- paste0(base_url, next_page_path)
  message("Mengekstrak [Halaman ", page_count, "]: ", current_url)
  page_data <- tryCatch({
    scrape_page(current_url)
  }, error = function(e) {
    warning("Gagal mengunduh halaman: ", current_url,
            " | Pesan: ", e$message)
    return(NULL)
  })
  if (!is.null(page_data)) {
    all_quotes <- bind_rows(all_quotes, page_data)
  }
  # Politeness: jeda acak antar permintaan
  Sys.sleep(runif(1, min = 1, max = 3))
  # Cari tautan tombol 'Next'
  html <- tryCatch(read_html(current_url),
                   error = function(e) NULL)
  if (is.null(html)) break
  next_btn <- html |> html_element(".pager .next a")
  next_page_path <- next_btn |> html_attr("href")
  page_count <- page_count + 1
}
# 4. Simpan hasil ke CSV
write.csv(all_quotes, "all_quotes.csv", row.names = FALSE)
```

Praktik Produksi: Backoff dan Toleransi Galat

```python
import time, random, requests

def get_with_backoff(url, headers, max_retries=5):
    for attempt in range(max_retries):
        r = requests.get(url, headers=headers, timeout=30)
        if r.status_code == 200:
            return r
        if r.status_code in (429, 503):
            wait = (2 ** attempt) + random.uniform(0, 1)
            time.sleep(wait)
            continue
        r.raise_for_status()
    raise RuntimeError(f"Gagal: {url}")
```

Rate limiting

- Jeda acak antar permintaan.

Exponential backoff

- Jeda menunggu berlipat saat 429/503.

Fault tolerance

- tryCatch (R) / try-except (Python); pipeline tidak berhenti di tengah jalan.

Pengambilan Data via Web API

GET	POST	PUT	DELETE
ambil data	kirim data baru	perbarui data	hapus data

Status	Arti
200 OK	Berhasil
404	Endpoint tidak ditemukan
429	Rate limit terlampaui
403	Akses ditolak (izin/autentikasi)

URL API = Endpoint + Query Parameters (?q=geek) + API Key. POST/PUT/DELETE umumnya butuh autentikasi.

Python

```python
url = "https://jsonplaceholder.typicode.com/posts"
r = requests.get(url)
if r.status_code == 200:
    data = r.json()       # list/dict Python
    print(data[0])
```

R

```r
library(httr); library(jsonlite)
base <- "https://api.dictionaryapi.dev/api/v2/entries/en/"
api <- paste0(base, "geek")
res <- GET(api)
txt <- rawToChar(content(res, as = "raw"))
data <- fromJSON(txt)
data$meanings[[1]]$definitions[[1]]$definition
```

Mekanisme HTTP, URL API, dan Status

GET

- Meminta/mengambil data dari sumber daya (tidak mengubah data server).

POST

- Mengirim data baru ke server, mis. membuat entitas baru.

PUT

- Memperbarui data yang sudah ada di server.

DELETE

- Menghapus data dari server.

Anatomi URL API

- Endpoint: alamat URL tujuan.
- Query Parameters: parameter pencarian, mis. ?q=geek.
- API Key: kode unik untuk identifikasi pengguna, mengelola lalu lintas, mencegah penyalahgunaan.
- POST, PUT, DELETE umumnya memerlukan autentikasi.

Status	Arti
200 OK	Berhasil, data dikirim kembali
404 Not Found	Sumber daya/endpoint tidak ditemukan
429 Too Many Requests	Rate limit terlampaui; skrip berhenti sementara
403 Forbidden	Akses ditolak: izin atau autentikasi

Integrasi API dengan Python (requests)

```python
import requests

# 1. Definisi endpoint API
url = "https://jsonplaceholder.typicode.com/posts"

# 2. Eksekusi permintaan GET
response = requests.get(url)

# 3. Validasi kode status HTTP response
if response.status_code == 200:
    print("Permintaan berhasil!")
    # 4. Parsing JSON ke tipe native Python
    data = response.json()
    # Menampilkan observasi pertama
    print("Contoh Data Pertama:", data[0])
else:
    print(f"Gagal. Status code: {response.status_code}")
```

Python

Nilai strategis API

- Jalur akses stabil dan terstruktur.
- Tidak terpengaruh perubahan antarmuka visual.
- Hemat daya komputasi dibanding scraping HTML.
- response.json() menghasilkan list/dictionary.

Alur API dengan Python

1	**Definisi endpoint**	url = "https://jsonplaceholder.typicode.com/posts".
2	**Permintaan GET**	response = requests.get(url).
3	**Validasi status**	Lanjut hanya jika status_code == 200; selain itu cetak pesan gagal.
4	**Parsing JSON**	response.json() menghasilkan list/dictionary; data[0] adalah observasi pertama.

Integrasi API dengan R (httr & jsonlite)

```r
library(httr)
library(jsonlite)

# 1. Permintaan HTTP GET
word <- "geek"
api_url <- paste0(
  "https://api.dictionaryapi.dev/api/v2/entries/en/", word)
response <- GET(api_url)

# 2. Konten mentah (raw) menjadi string karakter
raw_content <- content(response, as = "raw")
char_json <- rawToChar(raw_content)

# 3. Parsing JSON menjadi list/data frame R
data <- fromJSON(char_json)

# 4. Navigasi nested list
definition <- data$meanings[[1]]$definitions[[1]]$definition
print(definition)
```

Alur

- httr: komunikasi HTTP.
- jsonlite: parsing JSON.
- Data JSON bersarang diakses lewat hirarki list dengan [[1]] dan $.

Alur API dengan R

1	**Permintaan GET**	api_url dibentuk dengan paste0(endpoint, word), lalu GET(api_url).
2	**Konten mentah ke string**	content(response, as = "raw") lalu rawToChar().
3	**Parsing JSON**	fromJSON(char_json) menghasilkan list / data frame terstruktur.
4	**Navigasi nested list**	data$meanings[[1]]$definitions[[1]]$definition mengambil definisi spesifik.

Tidy Data (Aturan Codd ke-3)

1. **Setiap variabel membentuk satu kolom**
2. **Setiap observasi membentuk satu baris**
3. **Setiap tipe unit observasi membentuk satu tabel**

Masalah data berantakan	R (tidyr)	Python (pandas)
Header kolom berisi nilai (melting)	pivot_longer(cols = -religion, names_to, values_to)	pd.melt(id_vars, var_name, value_name)
Banyak variabel dalam satu kolom	separate_wider_delim(delim = "_", names = c("sex","age"))	str.split("_", expand=True) + drop
Variabel tersebar di baris (casting)	pivot_wider(names_from = element, values_from = value)	pivot(index, columns, values).reset_index()

Struktur = tata letak fisik; semantik = makna: value (angka/string), variable (atribut sama antar unit), observation (semua atribut satu unit).

Struktur Data vs Semantik Data

Variabel	Variabel	Variabel
Nilai	Nilai	Nilai
Nilai	Nilai	Nilai

Kolom = variabel; baris = observasi. Setiap tipe unit observasi menjadi satu tabel terpisah (bentuk normal ketiga Codd, dikembangkan Hadley Wickham).

Struktur vs Semantik

- Struktur: tampilan fisik tata letak tabel (baris dan kolom).
- Semantik: makna yang terkandung di dalam nilai data.

Nilai (Value)

- Setiap angka atau string yang diukur.

Variabel (Variable)

- Mengukur atribut sama (tinggi, suhu, pendapatan) di seluruh unit.

Observasi (Observation)

- Mengukur seluruh atribut pada unit yang sama (orang atau hari yang sama).

Masalah 1: Header Berupa Nilai (Melting)

Masalah dan solusi

- Header kolom menyimpan nilai variabel (mis. rentang pendapatan <$10k, $10-20k pada data survei). Solusi: pivoting longer / melting / stacking.

R (tidyr)

```r
library(tidyr)
library(dplyr)
raw_pew <- tibble(
  religion = c("Agnostic", "Atheist"),
  `<$10k` = c(27, 12),
  `$10-20k` = c(34, 27)
)
tidy_pew <- raw_pew |>
  pivot_longer(
    cols = -religion,
    names_to = "income",
    values_to = "frequency"
  )
```

Python (pandas)

```python
import pandas as pd
raw_pew = pd.DataFrame({
    'religion': ['Agnostic', 'Atheist'],
    '<$10k': [27, 12],
    '$10-20k': [34, 27]
})
tidy_pew = pd.melt(
    raw_pew,
    id_vars=['religion'],
    var_name='income',
    value_name='frequency'
)
```

Masalah 2: Banyak Variabel dalam Satu Kolom

Masalah dan solusi

- Satu kolom berisi lebih dari satu atribut (mis. m014 = jenis kelamin m + kelompok umur 0-14). Solusi: pemisahan string berbasis delimiter atau regex.

R (tidyr)

```r
raw_tb <- tibble(
  country = c("AD", "AE"),
  demo_group = c("m_0-14", "f_15-24"),
  cases = c(0, 3)
)
tidy_tb <- raw_tb |>
  separate_wider_delim(
    demo_group,
    delim = "_",
    names = c("sex", "age")
  )
```

Python (pandas)

```python
raw_tb = pd.DataFrame({
    'country': ['AD', 'AE'],
    'demo_group': ['m_0-14', 'f_15-24'],
    'cases': [0, 3]
})
raw_tb[['sex', 'age']] = (
    raw_tb['demo_group']
    .str.split('_', expand=True)
)
tidy_tb = raw_tb.drop(columns=['demo_group'])
```

Masalah 3: Variabel Tersebar (Casting)

Masalah dan solusi

- Baris berisi nama variabel, bukan nilai observasi (mis. kolom element memuat tmin dan tmax secara vertikal). Solusi: pivoting wider / unstacking.

R (tidyr)

```r
raw_weather <- tibble(
  id = rep("MX17004", 2),
  date = rep("2010-01-30", 2),
  element = c("tmax", "tmin"),
  value = c(27.8, 14.5)
)
tidy_weather <- raw_weather |>
  pivot_wider(
    names_from = element,
    values_from = value
  )
```

Python (pandas)

```python
raw_weather = pd.DataFrame({
    'id': ['MX17004', 'MX17004'],
    'date': ['2010-01-30', '2010-01-30'],
    'element': ['tmax', 'tmin'],
    'value': [27.8, 14.5]
})
tidy_weather = raw_weather.pivot(
    index=['id', 'date'],
    columns='element',
    values='value'
).reset_index()
tidy_weather.columns.name = None
```

Penyimpanan dan Ekspor Hasil Ekstraksi

Setelah data rapi sesuai Tidy Data, simpan ke penyimpanan lokal dalam format standar CSV (Comma-Separated Values).

R

```r
# Menyimpan data frame rapi ke CSV
write.csv(tidy_weather, "hasil_tidy_data.csv",
          row.names = FALSE)
```

Python

```python
# Menyimpan DataFrame pandas ke CSV
tidy_weather.to_csv("hasil_tidy_python.csv",
                    index=False, encoding="utf-8")
```

Catatan

- row.names = FALSE dan index=False mencegah kolom indeks tambahan.
- encoding="utf-8" menjaga karakter non-ASCII.

Pipeline Data dan Ringkasan

Legalitas & etika → Analisis DOM / API → Ekstraksi statis/dinamis → Tidy data → Ekspor CSV

R

```r
write.csv(tidy_weather, "hasil_tidy_data.csv", row.names = FALSE)
```

Python

```python
tidy_weather.to_csv("hasil_tidy_python.csv", index=False, encoding="utf-8")
```

Poin kunci

- Utamakan Web API jika tersedia; scraping untuk data yang tidak dibuka API.
- Patuhi ToS, robots.txt, privasi (PII), dan prinsip politeness.
- Pahami DOM dan uji selektor di DevTools sebelum menulis skrip.
- Situs dinamis: Selenium/chromote; produksi: rate limiting, backoff, fault tolerance.
- Rapikan menjadi Tidy Data agar siap untuk analisis lanjutan.

Ringkasan R vs Python

Tugas	R	Python
Permintaan HTTP/API	httr::GET	requests.get
Parsing HTML	rvest: html_elements	BeautifulSoup: select/find_all
Tabel HTML	html_table()	pandas.read_html (tambahan)
Otomasi browser	chromote	Selenium
Parsing JSON	jsonlite::fromJSON	response.json()
Wide ke long	pivot_longer	pd.melt
Long ke wide	pivot_wider	pivot + reset_index
Pisah kolom	separate_wider_delim	str.split(expand=True)
Ekspor CSV	write.csv	to_csv

Tugas: Pipeline Data Web

Bangun pipeline mini dari akuisisi hingga Tidy Data memakai situs latihan legal. Kerjakan dengan R atau Python (bebas pilih salah satu).

A. Scraping statis

- books.toscrape.com

B. Situs dinamis

- quotes.toscrape.com/js/

C. Web API

- api.open-meteo.com

Ketentuan

- Kumpulkan: skrip (.R / .py), file CSV hasil akhir, dan laporan singkat 1-2 halaman.
- Wajib: User-Agent kustom, jeda antar permintaan, dan cek robots.txt (jelaskan hasilnya).
- Hanya gunakan situs latihan di atas; jangan mengambil data pribadi (PII).

Tugas A: Scraping Statis Toko Buku

Instruksi

- Situs: books.toscrape.com (situs latihan toko buku fiktif).
- Ambil judul, harga, rating bintang, dan ketersediaan dari minimal 5 halaman katalog.
- Ikuti tombol Next (paginasi) dengan jeda acak 1-3 detik dan penanganan galat.
- Bersihkan harga menjadi angka dan rating menjadi 1-5.
- Simpan ke buku.csv.

Petunjuk

- Buka DevTools > Elements; tiap buku berada di elemen article.product_pod.
- Judul ada pada atribut title tag <a> di dalam h3.
- Harga: .price_color; rating: kelas pada p.star-rating (mis. Three).
- R: html_elements() lalu html_element() untuk menjaga baris; Python: select() atau find_all().

Tugas B: Situs Dinamis (JavaScript)

Instruksi

- Situs: quotes.toscrape.com/js/ (konten dirender JavaScript).
- Langkah 1: ambil dengan requests/rvest dan tunjukkan bahwa hasilnya kosong.
- Langkah 2: ambil dengan Selenium (Python) atau chromote (R) memakai explicit wait.
- Kumpulkan teks kutipan, penulis, dan tag dari minimal 3 halaman.
- Ambil screenshot salah satu halaman.

Petunjuk dan analisis

- Buka tab Network: adakah endpoint XHR yang bisa dipakai langsung?
- Jalankan headless dan bandingkan waktu eksekusinya.
- Tulis di laporan: mengapa pendekatan statis gagal di situs ini.
- Hasil: kutipan.csv.

Tugas C: Web API dan Tidy Data

Endpoint

```
https://api.open-meteo.com/v1/forecast
  ?latitude=-6.2&longitude=106.8
  &daily=temperature_2m_max,temperature_2m_min
  &timezone=Asia/Jakarta
```

Instruksi

- Ambil prakiraan cuaca harian (tanpa API key) dengan GET dan cek status 200.
- Parsing JSON; bentuk data frame dengan kolom tanggal, tmax, tmin.
- Ubah ke format panjang (kolom element: tmax/tmin dan value) dengan pivot_longer / melt.
- Kembalikan ke bentuk tidy dengan pivot_wider / pivot; simpan cuaca.csv.

Petunjuk

- Respons JSON memiliki objek "daily" berisi larik time, temperature_2m_max, temperature_2m_min.
- Setiap larik sama panjang; satu tanggal = satu observasi.
- Jelaskan di laporan: mana variabel, observasi, dan nilai pada data Anda.
- Pastikan memenuhi tiga aturan Tidy Data.

Situs Latihan dan Referensi

Situs	Dipakai untuk
rvest.tidyverse.org/articles/starwars.html	Ekstraksi section HTML (R)
web.archive.org (IMDB Top 250)	Tabel HTML dan regex
quotes.toscrape.com	Paginasi multi-halaman
scrapethissite.com/pages/forms	Selenium: formulir dan tabel
jsonplaceholder.typicode.com/posts	Web API (Python)
api.dictionaryapi.dev	Web API (R)

UNIVERSITAS SULTAN AGENG TIRTAYASA

UNTIRTA Jawara
Jujur Adil Wibawa Amanah Religius Akuntabel

Terima Kasih

Data Mining

Ferdian Bangkit Wijaya, S.Stat., M.Si.

